# Curso de Engenharia de Computação Sistemas Operacionais



Processos e Threads – Parte III



Slides da disciplina Sistemas Operacionais Curso de Engenharia de Computação Instituto Mauá de Tecnologia – Escola de Engenharia Mauá Prof. Marco Antonio Furlan de Souza



#### Conceitos

- Comunicação entre processos em execução é comum;
- Por exemplo, na linha de comando do Linux quando se utiliza pipes para redirecionar a saída de um processo à entrada de outro;
- Problemas que surgem na comunicação entre processos:
  - Como efetuar a comunicação?
  - Como garantir que dois ou mais processos possam operar sobre recursos em comum sem gerar inconsistências (exemplos: conta bancária, reservas aéreas):
  - Como sincronizar as operações entre dois processos?

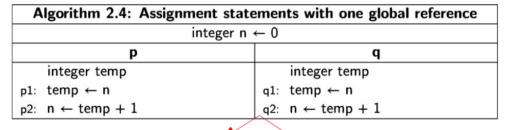


#### Condições de disputa

- Processos (e threads!) podem compartilhar armazenamento em comum (memória, arquivo em disco) e realizar nesse armazenamento operações de leitura e escrita;
- Quando dois ou mais processos tentam ler ou alterar algum recurso compartilhado e o resultado final depende da ordem de como os processos realizaram tais operações, tem-se uma condição de disputa (race condition).



- Condições de disputa
  - Exemplo
    - Os processos p e q ao serem executados em paralelo acessam a variável compartilhada n:



Dois cenários de execução! Qual deles é o correto?

Process p	Process q	n	p.temp	q.temp
p1: temp←n	q1: temp←n	0	?	?
p2: n←temp+1	q1: temp←n	0	0	?
(end)	q1: temp←n	1		?
(end)	q2: n←temp+1	1		1
(end)	(end)	2		

Process p	Process q	n	p.temp	q.temp
p1: temp←n	q1: temp←n	0	?	?
p2: n←temp+1	q1: temp←n	0	0	?
p2: n←temp+1	q2: n←temp+1	0	0	0
(end)	q2: n←temp+1	1		0
(end)	(end)	1		



#### Regiões críticas

- Para evitar condições de disputa, é necessário proibir que mais de um processo leia ou escreva um certo recurso compartilhado ao mesmo tempo;
- É necessário, portanto, estabelecer um esquema de exclusão mútua;
- A parte do programa que contém o recurso compartilhado é denominado de região crítica.

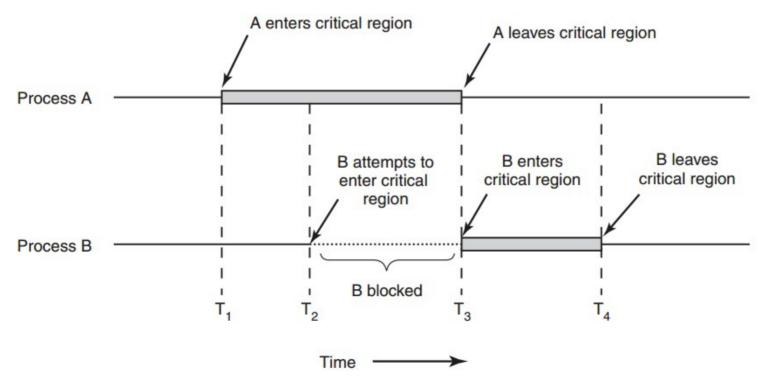


#### Regiões críticas

- Na realidade, as condições para evitar problemas de leitura/escrita de dois ou mais processos em um certo são as seguintes:
  - (1) Não se pode **permitir** que **dois processos** estejam executando **simultaneamente** dentro de suas **regiões críticas**;
  - (2) Não se pode assumir nada a respeito da velocidade ou número de CPUs (isso não deve afetar a corretude do algoritmo);
  - (3) Nenhum processo executando fora de sua região crítica poderá bloquear qualquer outro processo;
  - (4) Nenhum processo deverá esperar indefinidamente para entrar em sua seção crítica.



- Regiões críticas
  - Exclusão mútua por regiões críticas





- Exclusão mútua com espera ocupada
  - A exclusão mútua pode ser obtida pela técnica denominada espera ocupada (busy waiting);
  - Existem diversas propostas para implementar a espera ocupada:
    - Desabilitando interrupções;
    - Variáveis de travamento;
    - Alternância estrita;
    - Solução de Peterson;
    - Instrução TSL.



- Exclusão mútua com espera ocupada
  - Desabilitando interrupções
    - Em sistemas de um único processador, a solução mais simples é fazer com que cada processo que desabilite todas interrupções assim que entrar na seção crítica e reabilitá-las logo antes de sair desta seção;
    - Sem interrupções habilitadas, não ocorrem interrupções de relógio – a CPU só comuta de processo para processo com interrupção de relógio ou outras;
    - Portanto, uma vez que um processo desabilitou interrupções, ele pode examinar e atualizar uma memória compartilhada sem que qualquer outro processo intervenha.



- Exclusão mútua com espera ocupada
  - Desabilitando interrupções
    - Problemas com esta abordagem:
      - Não é inteligente dar aos processos a capacidade de ligar/desligar interrupções – e se um deles esquecer de restaurar as interrupções?
      - Em sistemas com múltiplas CPUs as interrupções afetadas são aquelas da CPU onde o processo em questão está executando o que acontece com as outras CPUs? Os processos delas poderão acessar a região crítica;
      - Essa técnica é utilizada raramente ...



- Exclusão mútua com espera ocupada
  - Variáveis de travamento
    - Variáveis de travamento (lock variables) são variáveis que indicam se um processo pode ou não executar em uma região crítica;
    - A dinâmica é a seguinte: uma variável de travamento é inicializada sempre com 0. Quando um processo deseja entrar em uma região crítica de código, ele inspeciona a variável. Se seu valor for 0, então o processo altera seu valor para 1 e entra na seção crítica; senão, se seu valor for 1 o processo aguarda até que seu valor retorne novamente à 0;
    - Então, o valor 1 indica que uma seção crítica está sendo utilizada por algum processo e o valor 0 indica que nenhum processo está utilizando a seção.



- Exclusão mútua com espera ocupada
  - Variáveis de travamento
    - Problemas com esta abordagem:
      - Pode acontecer o seguinte cenário: supor que um processo consulte uma variável de travamento e identifique que seu valor é 0;
      - Antes de ele alterar o valor da variável, o agendador agenda outro processo que inspeciona a mesma variável, identifica que o valor é 0 e prontamente altera seu valor para 1;
      - Supondo que o **agendador retorne** ao **primeiro processo**, **este segue alterando** a **variável** de travamento **para 1** (lembra, para ele ela tinha o valor 0)
      - Por fim, tem-se dois processos que estarão na mesma seção crítica de código ao mesmo tempo! O que não é aceitável...



- Exclusão mútua com espera ocupada
  - Alternância estrita
    - Observar o código a seguir:

Inicialmente, o Processo 0 inspeciona a variável turn (que indica a vez do processo), descobre que é 0 (valor inicial) e entra na região crítica. O Processo 1 também verifica que é 0 e aguarda em uma repetição testando continuamente se turn alterou para 1.



- Exclusão mútua com espera ocupada
  - Alternância estrita
    - Quando o Processo 0 deixa a seção crítica ele altera turn para 1, permitindo que o Processo 1 entre na região crítica de código.
    - Supor que o Processo 1 termine sua região crítica tão rápido de modo que ambos processos ainda estejam em suas regiões nãocríticas de código com turn com valor 0;
    - Admitir que, a seguir, o Processo 0 execute seu laço de repetição rapidamente e saia da região crítica e altere turn para 1. Nesse ponto, tanto Processo 0 quanto Processo 1 estão executando na seção não-crítica.



- Exclusão mútua com espera ocupada
  - Alternância estrita
    - Neste ponto, supor que o Processo 0 rapidamente termine suma região não-crítica e volte para o topo do seu laço de repetição. Mas o Processo 0 não pode entrar em sua região crítica pois turn vale 1 e então fica aguardando a sua entrada até que turn volte a ser 0 depende da velocidade do Processo 1 em alterar turn em 0;
    - Esse mecanismo de um processo ficar continuamente testando uma variável até que seu valor mude, é denominado de espera ocupada (busy waiting) e uma variável de travamento que é utilizada com espera ocupada é denominada spin lock.



- Exclusão mútua com espera ocupada
  - Alternância estrita
    - Problemas com esta abordagem
      - Esta abordagem não é aconselhável quando um dos processos é lento
         se o processo lento estiver na região não-crítica de código, ele afetará a entrada de outro processo na região crítica viola a regra (3);
      - Esta solução requer que os dois processos alternem-se estritamente na entrada de suas regiões críticas.



- Exclusão mútua com espera ocupada
  - Solução de Peterson
    - Utiliza duas funções, enter\_region(p) e leave\_region(p) que respectivamente devem ser executadas para entrar na região crítica e sair da região crítica de código;
    - O parâmetro p representa o número de um processo: pode ser 0 ou 1;
    - O algoritmo de Peterson é correto no acesso concorrente à região crítica de código: por utilizar duas variáveis cuja alteração se dá em estados distintos, sempre um dos processos vai entrar na região crítica antes do outro – mesmo quando há um acesso quase simultâneo;
    - A única crítica é ainda o uso da técnica de espera ocupada.



- Exclusão mútua com espera ocupada
  - Solução de Peterson

```
#define FALSE 0
#define TRUE 1
#define N
                                         /* number of processes */
                                         /* whose turn is it? */
int turn:
                                         /* all values initially 0 (FALSE) */
int interested[N];
void enter_region(int process);
                                         /* process is 0 or 1 */
     int other:
                                         /* number of the other process */
     other = 1 - process;
                                         /* the opposite of process */
     interested[process] = TRUE;
                                         /* show that you are interested */
     turn = process;
                                         /* set flag */
     while (turn == process && interested[other] == TRUE) /* null statement */;
void leave_region(int process)
                                         /* process: who is leaving */
     interested[process] = FALSE;
                                         /* indicate departure from critical region */
```



- Exclusão mútua com espera ocupada
  - Instrução TSL
    - Neste caso, utiliza-se alguma instrução do processador para implementar o acesso à memória, criando um travamento em uma certa posição dela – válida para sistemas multiprocessados;
    - Pode-se imaginar uma instrução como TSL RX, LOCK (Test and Set Lock) que funciona assim: ela lê o conteúdo da posição de memória travada LOCK em RX e então armazena um valor não zero na posição de memória que está travada (LOCK). As operações de ler da memória travada e de escrever nela são garantidas a serem indivisíveis nenhum outro processador pode acessar esta palavra de memória até a instrução termine, com a restauração do valor de LOCK.
    - A técnica é correta. O travamento ocorre a nível de bus mas ainda é um exemplo da técnica de espera ocupada.



- Exclusão mútua com espera ocupada
  - Instrução TSL
    - Exemplo



- Exclusão mútua com espera ocupada
  - Críticas finais sobre esta técnica:
    - Há um gasto desnecessário de CPU (por conta da espera ao acesso);
    - Ocorre o problema da inversão de prioridade:
      - Supondo dois processos, H, com alta prioridade e L com baixa prioridade.
         O agendador sempre escolhe executar H quando ele está pronto;
      - Em um dado momento, L está na sua região crítica de código e então supor que H volta a ficar no estado pronto (após uma interrupção de E/S)
      - Só que H fica em espera ocupada, mas desde que L não é agendado para continuar (baixa prioridade) L nunca tem a chance de sair da região crítica de código e H fica eternamente esperando entrar lá.



#### Dormir e acordar

- Nesta técnica, no lugar de os processos gastarem CPU aguardando a liberação de um recurso, eles são suspensos "dormem" até que possam ser reativados "acordar" e acessar o recurso;
- Primitivas de comunicação
  - sleep: é uma chamada de sistema que faz com que o processo chamador seja suspenso até que outro processo o acorde;
  - wakeup: é uma chamada de sistema que acorda um processo passado como parâmetro.



#### Dormir e acordar

- O problema do Produtor-Consumidor
  - Também conhecido como o problema do Buffer Limitado;
  - Dois processos compartilham um buffer comum, de tamanho fixo. Um deles, o produtor, escreve dados no buffer, e o outro, o consumidor, os retira (é possível generalizar o problema para ter m produtores e n consumidores, mas considerar o caso de um produtor e um consumidor simplifica as soluções.);

#### Problemas:

- O produtor quer colocar um novo item no buffer mas este já cheio. A solução é que o produtor durma e seja despertado quando o consumidor removeu um ou mais itens;
- O consumidor quer remover um item do buffer e percebe que o buffer está vazio. Ele vai dormir até que o produtor coloque algo no buffer e acorde.



- Dormir e acordar
  - O problema do Produtor-Consumidor
    - Exemplo de implementação

```
#define N 100
                                                      /* number of slots in the buffer */
                                                      /* number of items in the buffer */
int count = 0;
void producer(void)
     int item;
     while (TRUE) {
                                                      /* repeat forever */
                                                      /* generate next item */
           item = produce_item();
                                                      /* if buffer is full, go to sleep */
           if (count == N) sleep();
           insert_item(item);
                                                      /* put item in buffer */
                                                      /* increment count of items in buffer */
           count = count + 1;
           if (count == 1) wakeup(consumer);
                                                      /* was buffer empty? */
```



- Dormir e acordar
  - O problema do Produtor-Consumidor
    - Exemplo de implementação (cont.)



- Dormir e acordar
  - O problema do Produtor-Consumidor
    - A solução possui os mesmos problemas de condição de disputa como já apresentado;
    - Para controlar o número de itens no buffer, utiliza-se a variável count;
    - Código do produtor: se o número máximo de itens que o buffer pode comportar é N, o produtor primeiro testa para verificar se count é N; se for, o produtor dormirá; senão o produtor adicionará um item ao buffer e incrementará a variável count;
    - Código do consumidor: ele primeiramente testa a variável count para verificar se é zero. Se for, então ele dormirá; senão ele removerá um item e decrementará a variável counter.



- Dormir e acordar
  - O problema do Produtor-Consumidor
    - A condição de disputa neste problema ocorre porque o acesso à variável count é irrestrito;
    - Pode ocorrer a seguinte situação: o buffer está vazio e o consumidor acabou de ler o valor de count para checar se é 0. Nesse instante, o agendador decide parar a execução do consumidor temporariamente e iniciar a execução do produtor;
    - O produtor insere um item no buffer, incrementa count e verifica que agora é 1.
       Depois, o produtor executa wakeup para acordar o consumidor. Mas o consumidor não está logicamente dormindo e o sinal wakeup é perdido.
    - Quando o consumidor volta a executar, ele testa o último valor de count lido, que é
       0 e então volta a dormir. Mais cedo ou mais tarde o produtor preencherá o buffer e também dormirá;
    - Por fim ambos dormirão eternamente...

# Referências bibliográficas



TANENBAUM, Andrew S. **Sistemas operacionais modernos**. 3. ed. São Paulo: Pearson, 2013. 653 p.